HY4 BF16权重模型算子功能支持分析

依据既有减层 Profiling 离线生成；没有新启动模型、bench、Profiler 或裁判 API。

> **结论：**本报告分析 BF16 权重模型所使用的全部已采集算子/任务，不限定其 I/O 必须为 BF16。4760 条任务均来自成功轮次，FP32、整数、BOOL、AI_CPU 及 dtype 未报告的执行记录均纳入模型功能支持证据。已观察到 BF16 投影 GEMM、Grouped GEMM、RMSNorm、稀疏 Attention、Indexer、SwiGLU、KV/cache 等路径在当前形状下实际执行。它们的 I/O dtype 与引擎有直接记录；这不等于全量模型全部算子支持认证，也不证明内部累加全部为 BF16。

> **本报告的支持口径：**算子在当前记录的 dtype/shape 下实际执行成功即计为功能支持，AI_CPU 与 AI Core/Vector 一样计入功能支持；引擎单独列示。未采到的路径为未覆盖；dtype 缺失仅表示类型元数据未知，已有执行记录仍计为模型功能支持证据。当前没有观察到能直接判为 BF16 不支持的失败证据。

1. 范围与证据统计

指标	结果
范围	减层 2L、TP2、两张 A5；每 rank 中段 decode 10 步
采集调用 / kernel 名称	4760 次 / 89 个名称（不等于前端算子数）
直接记录到 BF16 I/O	1900 次；26 种 CANN/自定义 Type
BF16 I/O 且在 AI Core/Vector/Mixed	1820
BF16 I/O 且在 NPU 侧 AI_CPU	80
未报告 I/O dtype 的计算调用	320
全量 kernel 级支持率	不可由当前采样计算，未给出 100% 支持结论

模型为 HY4 2L（1 Dense + 1 MoE），物理卡 2、3，TP2/DP1；请求实际输入 32768、输出 4096 token。每 rank 在延迟 2048 个 worker 步后记录中段 10 步。**这是 decode 窗口，不能把整个请求成功等同于视觉/prefill 的逐算子 dtype 已采到。**

2. 主要模块支持证据

模块/路径（均已观测执行）	调用数（两卡合计）	BF16 I/O 元数据调用	执行引擎	dtype 元数据分类
投影 GEMM	380	320	AI_CORE, MIX_AIC	bf16_io_observed, no_bf16_io_observed
MoE Grouped GEMM	40	40	AI_CORE	bf16_io_observed
RMSNorm	140	140	AI_VECTOR_CORE	bf16_io_observed
稀疏注意力	40	40	MIX_AIC	bf16_io_observed
Lightning Indexer	40	40	MIX_AIC	bf16_io_observed
RoPE / KV cache	80	80	AI_VECTOR_CORE	bf16_io_observed
RoPE API	80	80	AI_VECTOR_CORE	bf16_io_observed
SwiGLU	60	60	AI_VECTOR_CORE	bf16_io_observed

模块/路径（均已观测执行）	调用数（两卡合计）	BF16 I/O 元数据调用	执行引擎	dtype 元数据分类
MoE Dispatch / Combine	40	40	AI_VECTOR_CORE, MIX_AIV	bf16_io_observed
Embedding	20	20	AI_VECTOR_CORE	bf16_io_observed
Index（AI_CPU，功能支持）	80	80	AI_CPU	bf16_io_observed
iHC Triton（dtype 未报告）	240	0	AI_VECTOR_CORE	dtype_unreported
RoPE Triton（dtype 未报告）	80	0	AI_VECTOR_CORE	dtype_unreported
MoE Router（FP32 路径）	20	0	AI_VECTOR_CORE	no_bf16_io_observed

`bf16_io_observed`：输入或输出字段明确包含 BF16。`dtype_unreported`：输入与输出类型均为空/N/A。
`no_bf16_io_observed`：记录了其他类型；不代表 BF16 不支持。表内模块归类基于 kernel 名称，并非完整调用栈映射。

3. 需要单列的结果

- **BF16 Index 在 AI_CPU 上执行：**两卡合计 80 次，kernel 为 `aclnnIndex_IndexAiCpu_Index`，明确记录 BF16 输入/输出和整数索引。该路径能执行，但不是 AI Core/Vector 路径。AI_CPU 是设备侧 CPU，**这 80 次执行按功能支持口径明确计为已实测支持**；不能写成宿主机回退或"不支持 BF16"。是否需要性能优化是另一个问题。
- **自定义 Triton 路径已执行，类型元数据未报告：**_ihc_post_kernel, _ihc_pre_stage1, _ihc_pre_stage2, _triton_rope_siso。这些 kernel 在设备上有执行记录，但 dtype 字段缺失，因此计为已观测执行；仅不宣称其具体 I/O/内部算术类型。
- **FP32/整数路径并非错误：**Router、部分归一化/采样和索引包含 FLOAT、INT32/INT64、BOOL。混合 dtype 不能算作 BF16 支持失败。DT_UNDEFINED 也可能是未提供的可选输入。
- **执行成功不等于逐算子数值精度认证：**当前没有逐 kernel 与高精度参考的数值误差对照；全量数据集精度结果属于模型级证据。

4. 执行引擎统计

引擎	调用数	累计 kernel 耗时 μs（跨两卡相加）
AI_VECTOR_CORE	3840	25388.018
AI_CPU	220	18782.407
COMMUNICATION	40	21687.846
MIX_AIC	240	8949.384
AI_CORE	360	19872.656
MIX_AIV	60	809.146

> 所有耗时都是记录的 kernel duration 之和，可能有重叠，也跨两个设备，不能当作墙钟耗时、batch 时延或端到端吞吐。数据中的通信与调度记录独立列出，不用它们推断 BF16 算术支持率。此前 weighted_attainment=1.0972 是另一套经验效率指标，不是本报告的支持率。

5. 本次未覆盖的范围

- Observed workload/shape coverage only; no universal operator-support percentage.
- No dtype-specific reference numerical validation per kernel; successful execution is not a numerical precision certification.
- Vision/prefill kernels are not covered by the middle-decode window; MTP is not enabled in this profile.
- Full 78-layer multi-node model completed accuracy evaluation, but no full-model kernel profiling was collected.
- Shared-indexer layers, multi-node expert communication, other shapes, concurrency, CP, reload and transfer are not certified by this profile.
- Optional DT_UNDEFINED arguments do not alone mean an unsupported datatype.

四机全量 BF16 的 GPQA 185/198、Hallusion aAcc 79.1851% 已有独立报告，但没有全量 kernel 级 Profiling，因此不能将本报告中的次数和耗时乘 39 外推 78 层。MTP、共享 Indexer、跨机专家通信以及视觉/prefill 等需要相应窗口的真实采集。

6. 逐 kernel 明细

7. 下载与可复核来源

- 逐 kernel 汇总 CSV
- dtype/shape 明细 CSV
- 4760 次原始证据行 CSV
- 模块矩阵 CSV
- 完整机器可读 JSON（含来源 SHA256 和行号）
- Excel 汇总与逐项明细
- GitHub 原始 Profiling

生成时间：2026-10-31T07:53:30.623409+00:00。这是一份观测覆盖报告，结论限定于记录到的 workload / shape / 环境。